RITAL : Chirac ou Mitterrand ? Comm' positif ou négatif ?

Etudiant : **Nils Barrellon 21401602**

Github associé : https://github.com/nbarrellon/RITAL2026

1 Formulation du problème

Chirac ou Mitterrand : on dispose de la transcription d'un débat entre les deux présidents de la République, MM Chirac et Mitterrand. Chaque phrase prononcée par l'un ou l'autre est labellisée. On attribue le label M pour celles proposées par M.Mitterrand que l'on convertit en -1 et le label C (converti en 1) si c'est M.Chirac qui parle.
Les phrases labellisées de ce débat constitueront donc les données d'entraînement.
L'objectif du projet est de pouvoir attribuer à son auteur une phrase quelconque prononcée dans un autre contexte : on parle de **diarisation du locuteur**.

Commentaire positif ou négatif : la dataset est constituée d'une banque de commentaires autour de différents films. L'objectif est de décider si tel ou tel commentaire est un commentaire positif ou négatif : on parle ici d'**analyse de sentiment**.

2 Etude du problème de diarisation du locuteur

2.1 Bag of words

On crée différents bag of words (*bog*) pour nos documents afin d'en tester la pertinence.

2.1.1 Pré-processing

On effectue en amont de la construction du *bog* un nettoyage du texte. Les options retenues sont :

- suppression de la ponctuation ;
- suppression des chiffres ;
- mise en minuscule ;

Ce nettoyage est opéré par la fonction personnalisée de pré-processing suivante :

```
import codecs
import re
import string
from unidecode import unidecode

def preprocessPerso(text):
    #suppression de la ponctuation
    punc = string.punctuation
    punc += '\n\r\t'
    text = text.translate(str.maketrans(punc, ' '*len(punc)))
    #suppression des chiffres
    text = re.sub(r"[0-9]","",text)
```

```
    #suppression des accents
    text = unidecode(text)
    #mise en minuscule
    return text.lower()
```

2.1.2 Stopwords

On supprime les mots blancs avant construction du *bog*. La liste des stopwords est obtenue par concaténation des stopwords français donnés par la bibliothèque `nltk` auxquels on ajoute une liste personnelle, établie à partir de la liste des mots les plus présents et non-discriminants.

```
# Mots blancs + mots les plus fréquents

nltk.download('stopwords')
from nltk.corpus import stopwords
final_stopwords_list = stopwords.words('french')
#mots les plus fréquents donc non-discriminants
final_stopwords_list += ['ai','au','aujourd','aussi','autres','aux','
   avec','avez' ,'avons',
 'bien', 'ce' ,'cela', 'ces', 'cette' ,'ceux', 'chacun' ,'comme', '
    dans' ,'date'
 'de', 'depuis', 'des' ,'deux' ,'dire' ,'doit' ,'dont' ,'du'
 'elle' ,'en' ,'encore', 'ensemble', 'entre', 'est' ,'et', 'etat', '
    ete' ,'etre',
 'europe' ,'faire' ,'fait' ,'faut', 'francais' ,'france', 'hui' ,'ici'
    , 'il' ,'ils',
 'je' ,'la', 'le' ,'les', 'leur' ,'leurs', 'mais', 'meme' ,'monde', '
    monsieur' ,'ne',
 'nom', 'nos', 'notre', 'nous', 'on', 'ont' ,'ou', 'paix', 'par', 'pas
    ', 'pays',
 'peut' ,'plus' ,'politique' ,'pour', 'president' ,'qu', 'que' ,'qui',
     'sa', 'sans',
 'se' ,'ses' ,'si' ,'son' ,'sont', 'sur', 'temps', 'tous', 'tout', '
    toute' ,'toutes',
 'tres', 'un' ,'une' ,'union', 'vie', 'vos' ,'votre', 'vous']
```

Cette liste a été obtenue à l'aide du script ci-dessous :

```
from sklearn.feature_extraction.text import TfidfVectorizer

use_idf=True
smooth_idf=True
sublinear_tf=False

vectorizer = TfidfVectorizer(preprocessor=preprocessPerso,use_idf=
   use_idf, smooth_idf=smooth_idf, sublinear_tf=sublinear_tf,
```

```
    max_features=100)
BOW1 = vectorizer.fit_transform(alltxts)
vocabulaire = vectorizer.get_feature_names_out()
```

2.1.3 Premier bog

Bag of words simple. Taille du vocabulaire = 26894

```
vectorizer1 = CountVectorizer(stop_words=final_stopwords_list,analyzer
    ="word", preprocessor=preprocessPerso)
BOW1 = vectorizer1.fit_transform(alltxts)
```

2.1.4 Deuxième bog

Utilisation de TF-IDF. Nombre de mots du vocabulaire : 2000

```
use_idf=True
smooth_idf=True
sublinear_tf=False

vectorizer2 = TfidfVectorizer(use_idf= use_idf, smooth_idf=smooth_idf
    ,\
sublinear_tf=sublinear_tf,                          preprocessor=
    preprocessPerso,stop_words=final_stopwords_list,max_features=2000)
BOW2 = vectorizer2.fit_transform(alltxts)
```

être
où
date
français
président
très
développement
avenir
histoire
beaucoup
toujours
économique
abord
notamment
elles
société
messieurs
sécurité
place
ans
enfin
liberté
jeunes
grande
confiance
entreprises
européenne
solidarité
déjà
volonté
également
grand
mesdames
oeuvre
état
naturellement
esprit
sociale
croissance
afrique
sûr
trop
pense
là
mieux
respect
sens
part
quand
contre
non
chaque
fois
autre
années
moyens
hommes
nouvelles
culture
démocratie
république
nouvelle
souhaitesouvent
travail
alors
service
ainsi
jamais
coeur
grands
après
progrès
avoir
dialogue
quelques
année
premier
action
parce
droit
donc
cet
emploi
doivent
coopération
communauté
devons
celle
nation
peuples
première
amitié
moyens
gouvernement
sous
naturellement
voudrais
besoin
peu
forte
partenaires
nouveau
grandes
croissance
ailleurs
vrai
nations
avant
essentiel
afrique
sûr
pense
là
mieux
sens
respect
ans
liberté
jeunes
enfin
fois
autre
années
hommes
nouvelles
culture
démocratie
république

```
nlp = spacy.load("fr_core_news_sm", disable=["parser", "ner"])

def lemmatisation(text, stopwords):
    text = preprocessPerso(text)
    doc = nlp(text.lower())
    # Lemmatiser uniquement les mots qui ne sont pas des stopwords
    lemmatized = [token.lemma_ for token in doc if token.text not in
        stopwords]
    text = " ".join(lemmatized).strip()
    #on supprime les espaces surnuméraires créés par la racinisation
    text = re.sub(r'\s+', ' ', text)
    return text

# Pré-traiter tous les textes
alltxts_lemmatise = []
for text in alltxts:
    alltxts_lemmatise.append(lemmatisation(text, final_stopwords_list)
        )
```

Le résultat est très probant comme le montre l'exemple ci-dessous (1re phrase du débat avant et après racinisation) :

```
C'est toujours très émouvant de venir en Afrique car c'est probablement
l'une des rares terres du monde où l'on ait conservé cette convivialité,
cette amitié, ce respect de l'autre qui s'expriment avec chaleur, avec spontanéité
et qui réchauffent le coeur de ceux qui arrivent et de ceux qui reçoivent.

-------------------------------
être toujours tre emouver venir afrique car être probablement rare terre avoir
conserve convivialite amitie respect autre exprimer chaleur spontaneite rechauffer
coeur celui arriver celui recoiver
```

Taille du vocabulaire = 19049

On note que, sans surprise, les auxiliaires **être** et **avoir** arrivent en tête des mots les plus fréquents. Il convient donc de les ajouter aux mots blancs.
A noter : ce processus de racinisation est très long et j'ai donc sauvegardé le vocabulaire obtenu pour ne pas avoir à le recalculer à chaque fois.

```
with open("corpus_nettoye_lemmatise.txt","w",encoding="utf-8") as f:
    for i in range(len(alltxts_lemmatise)):
        f.write(alltxts_lemmatise[i])
        f.write("\n")
```

2.1.7 Cinquième bog

On conjugue bigrammes et racinisation. Taille du vocabulaire = 345610

```
ngram_range = (1,2)
final_stopwords_list += ['avoir',"être"]
vectorizer5 = CountVectorizer(ngram_range=ngram_range,analyzer='word'
    ,\
stop_words=final_stopwords_list,preprocessor=preprocessPerso)
BOW5 = vectorizer5.fit_transform(alltxts_lemmatise)
```

avoir
entrer
social
celer
prendre
international
permettre
mettre
avenir
action
falloir
souhaiter
travail
autre
beaucoup
annee
mieux
enfin
jeune
fort
service
tre
peuple
aller
toujours
emploi
domaine
entreprise
histoire
donner
quelque
liberte
nouveau
savoir
francai
economiqu
premier
effort
nation
venir
parce
societe
grand
devoir
notamment
chaque
place
droit
an
date
abord
voir
vouloir
pouvoir
celui
national
homme
developpement
avoir
avoir
securite
moyen
agir
luire
eter
solidarite
public
culture
tenir
important
naturellement
communaute
relation
institution
recherche
responsabilite
ainsi
valeur
esprit
ambition
croissance
dialogue
meilleur
passer
essentiel
engager
mondial
general
objectif
afrique
plan
region
heureux
ville
car
trop
role
siecle
besoin
necessair
peu
ouvrir
projet
problème
moment
cote
loi
long
vrai
part
situation
particulier
relation
institution
recherche
formation
aide
economie
communaute
luire
eter
entendre
famille
souvent
reforme
principe
egalement
parler
lequel
saluer
certain
connaitre
gouvernement
rendre
trouver
importer
heure
avant
car
ville
chaque
an
confiance
vrai
economie
communaute
part
aide
formation
institution
recherche
relation
particulier
naturellement
situation
alors
moins
meilleur
democratie
accord
nombreux
systeme
tel
meilleur
marche
bon
ainsi
solidarite
important
culture
tenir
rendre
gouvernement
croissance
valeur
esprit
ambition

2.1.8 Sixième bog

On travaille avec un bog binaire. Taille du vocabulaire = 10000

```
min_df=5
max_df=0.5
max_features=10000
vectorizer6 = CountVectorizer(max_df=max_df,min_df=min_df,max_features
   =max_features,\
binary=True,stop_words=final_stopwords_list)
BOW6 = vectorizer6.fit_transform(alltxts)
```

date
être
français
ou
développement
président
sécurité
notamment
grande
toujours
placebeaucoup
très
elles
enfin
abord
cet
ans
devons
avenir
économique
européenne
histoire
société
grand
là
dialogue
entreprises
premier
esprit
hommes
souvent
chaque
service
démocratie
jeunes
travail
solidarité
communauté
nouvelles
domaine
contre
trop
social
alors
sociale
fois
celle
année
emploi
également
parce
droit
non
autre
besoin
culture
première
ainsi
progrès
qualité
souhaite
général
sous
vers
droits
coopération
afrique
internationale
nationale
française
croissance
action
mesdames
voudrais
volonté
gouvernement
confiance
avoir
peuples
nouvelle
rôle
grandes
messieurs
sens
sais
année
année
homme
mieux
force
donc
pense
quand
avant
ailleurs
respect
pourquoi
dit
tant
amitié
car
coeur
après
donner
part
jamais
nouveau
nouveaux
moins
état
conseil
quelques
moyens
liberté
doivent
oeuvre
déjà
grands
partenaires
forte
sûr
publics
publics
publics

```
use_idf=True
smooth_idf=True
sublinear_tf=False
vectorizer8 = TfidfVectorizer(use_idf= use_idf, smooth_idf=smooth_idf,
    sublinear_tf=sublinear_tf,\
                              stop_words=final_stopwords_list,
                                 max_features=4000)
BOW8 = vectorizer8.fit_transform(alltxts_lemmatise)
```

2.1.11 Neuvième bog

Je me suis aperçu, en séparant les données par locuteur en 2 corpus distincts, que M.Chirac a beaucoup plus parlé que M.Mitterrand lors de ce débat.

```
corpus1 = [alltxts[i] for i in range(len(alltxts)) if alllabs[i]==1] #
   Chirac
corpus2 = [alltxts[i] for i in range(len(alltxts)) if alllabs[i]==-1]
   #Mitterand

#Taille des corpus
print("------------------Taille des corpus-----------------------")
print("Chirac:",len(corpus1))
print("Mitterrand",len(corpus2))
```

```
------------------Taille des corpus-----------------------
Chirac: 49890
Mitterrand 7523
```

Ceci a une influence considérable sur l'entrainement et les prédictions des différents modéles. La métrique de la précision, très bonne quelque soit le *bog* utilisé, n'est plus pertinente.

D'autre part, il m'a semblé pertinent de ré-équilibrer les données. J'ai donc créé un neuvième *bog* en ramenant le nombre d'interventions de M.Chirac à un nombre égal à celui de M.Mitterrand.

```
corpus1 = [(alltxts_lemm[i],alllabs[i]) for i in range(len(alltxts))
   if alllabs[i]==1] #Chirac
corpus2 = [(alltxts_lemm[i],alllabs[i]) for i in range(len(alltxts))
   if alllabs[i]==-1] #Mitterand

corpus = corpus2+corpus1[:len(corpus1)//6]
new_alltxts = [c[0] for c in corpus]
new_labels = [[c[1] for c in corpus]]

ngram_range = (1,2) # unigrams and bigrams
```

```
use_idf=True
smooth_idf=True
sublinear_tf=False

vectorizer9 = TfidfVectorizer(ngram_range=ngram_range,analyzer="word",
   use_idf= use_idf, smooth_idf=smooth_idf, sublinear_tf=sublinear_tf
   ,\
                              stop_words=final_stopwords_list,
                                 max_features=5000)
BOW9 = vectorizer9.fit_transform(new_alltxts)
```

Taille du vocabulaire = 5000

pouvoir
devoir
falloir
celui
savoir
autre
vouloir
entrer
homme
francai
aller
beaucoup
premier
toujours
permettre
venir
celer
prendre
annee
societe
droit
croire
trouver
parce
agir
besoin
nouveau
grand
date
tre
eter
peuple
quelque
histoire
economique
mettre
force
souhaiter
social
jeune
fort
passer
luire
avenir
penser
nationabord
mieux
moyen
action
domaine
probleme
effort
alors
connaitre
europeen
travail
liberte
guerre
emploi
seul
gouvernement
essentiel
region
projet
avant
realite
entendre
international
engager
question
confiance
tant
cote
ville
fois
responsabilite
pourquoi
general
important
esprit
entreprise
communaute
national
dialogue
culture
certain
souvent
donner
chaque
rendre
republique
ministre
institution
moment
developpement
non
ambition
objectif
appeler
voir
vivre
loi
trop
respect
europeenn
aide
particulier
femme
exemple
couleur
notamment
ami
interet
donc
dejer
enfin
peu
conseil
tenir
principe
car
situation
heure
assurer
quel
marche
devant
chose
valeur
progre
oeuvre
quand
public
service
volonte
facon
cas
exister
ouvrir
democratie
rien
formation
necessair
loin
relation
afrique
mettre
part
raison
point
systeme
partenaire
pari
lequel
tel
possible
condition
naturellement
moins
jour
role
nombreux
bon
ailleurs
aucun
mesure
ecole
ainsi
plan
choix
accord
reste
jamais
nombre
securite
commun
compte
siecle
vrai
relation
an
solidarite
reste
meilleur
famille
longtemps
meilleur
cooperation
contre
donner
chaque
rendre
institution
moment
ministre
republique

La **régression logistique** modélise la probabilité d'appartenir à une classe via une fonction sigmoïde appliquée à une combinaison linéaire des mots. C'est un modèle linéaire qui une frontière de décision droite entre les classes.

La méthode **SVM pour Support Vector Machine** cherche l'hyperplan qui sépare les classes avec la marge maximale entre les points les plus proches de chaque classe (les vecteurs de support). Grâce à l'astuce du kernel, il peut projeter les données dans un espace de dimension supérieure pour séparer des classes non linéairement séparables.

4 Métriques

J'ai testé les 3 méthodes de classification sur chacun des *bog* et mesuré 3 métriques différentes sur les données test : la précision, le rappel et le f1-score. La figure montre de plus le temps d'exécution des 3 modèles pour chaque *bog*.

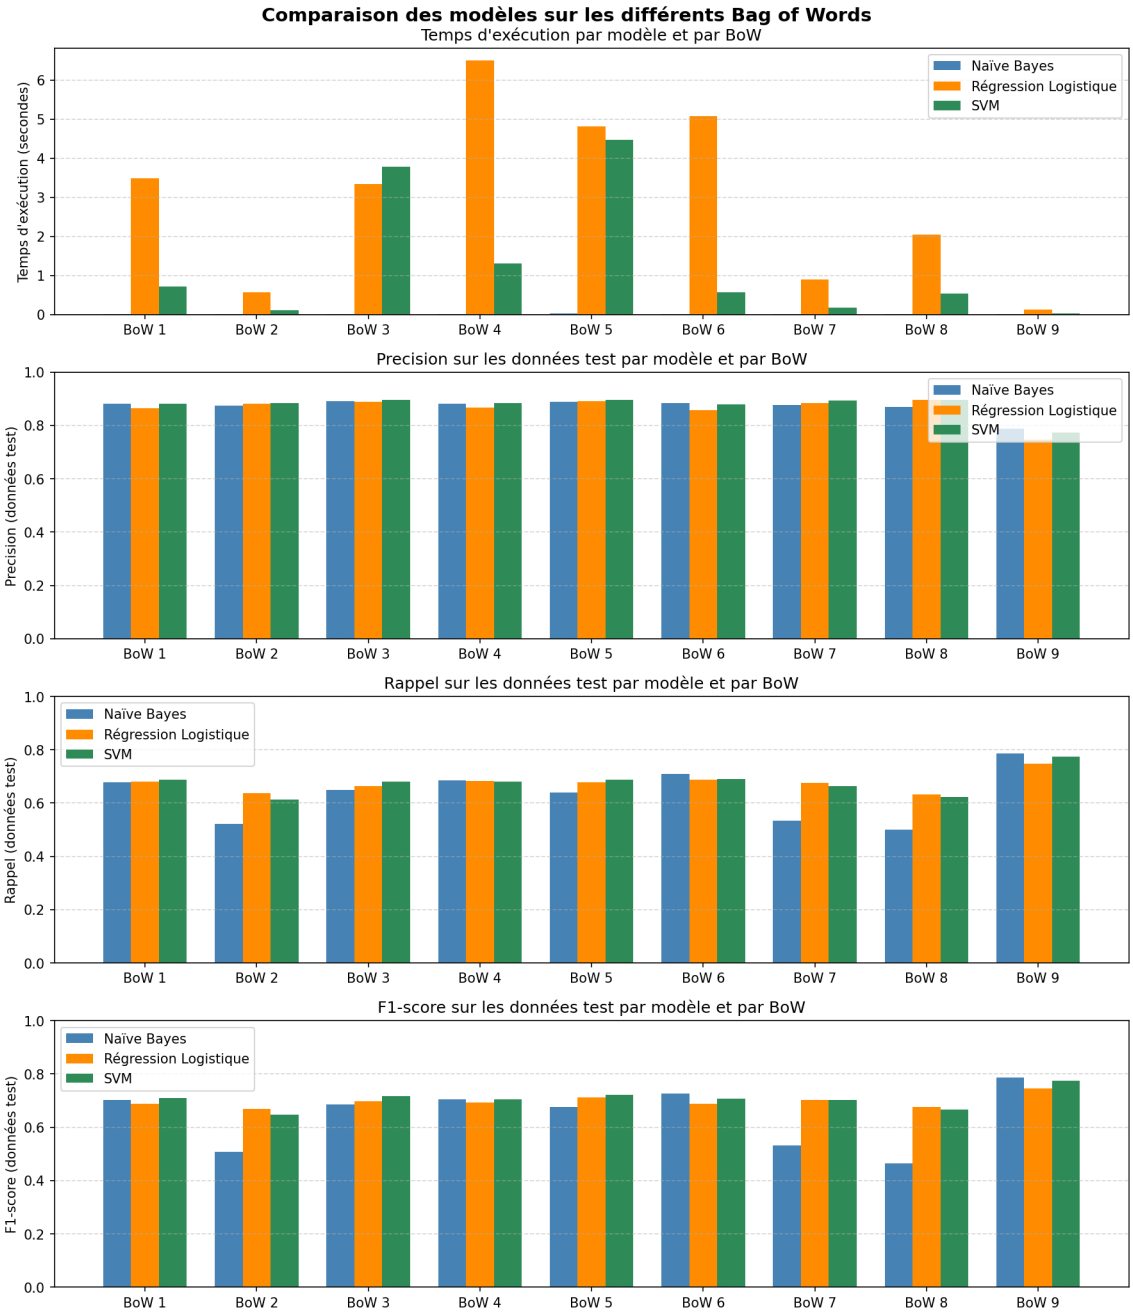

Le ré-équilibrage des données semble mener à un résultat de meilleure qualité. J'ai donc testé ce *bog* pour ma première soumission de données sur la plateforme.
Voici le script que j'ai utilisé pour générer mon fichier de résultats :

```
#Choix du bog
vectorizer = vectorizer9

#Application du BOG sur les données à tester
test_nouvelles_phrases = vectorizer.transform(nouvelles_phrases)
```

```
X_train = BOW9
y_train = new_labels #alllabs si BOG != BOG9 (plus petit)

#Choix du modèle
model = LogisticRegression(random_state=0, solver='liblinear',
   max_iter=100, tol=1e-8, C=100.0)

# Entrainement le modèle
model.fit(X_train, y_train)

#appliquer le même BOW sur les phrases mystère

probabilites = model.predict_proba(test_nouvelles_phrases)[:, 1]  #
   Probabilité classe "Chirac"

# Créer un DataFrame avec les probabilités
df = pd.DataFrame({
    "phrase": nouvelles_phrases,
    "probabilite_chirac": probabilites
})

# Écrire dans un fichier CSV
df.to_csv("probabilites_chirac.csv", index=False, header=False,columns
   =["probabilite_chirac"])
```

Cette première soumission m'a rendu les métriques suivantes :

- f1 =35.052
- auc = 70.976
- ap = 29.524

Ces résultats m'ont énormément surpris puisque très différents de ceux obtenus sur les données test. J'ai donc cru que je m'étais trompé de probabilité et ai soumis un nouveau fichier csv contenant `1-proba`. Les résultats étaient pires. Comment expliquer ces mauvais scores ?
J'ai dans l'idée que la normalisation était inadaptée : la racinisation pourrait bien avoir supprimé des informations utiles. J'ai donc soumis les données obtenues avec le premier *bog*.